

CST-S2TT Project Specification

Conversational Simultaneous Speech-to-Text Translation

Version 0.1 | Research Project Specification

프로젝트 가칭	Conversational Simultaneous Speech-to-Text Translation (CST-S2TT)
Benchmark 가칭	CST-Bench
핵심 범위	2 인 cross-lingual multi-turn conversation + simultaneous S2TT + interaction control
제외 범위	TTS/S2ST, voice quality, multi-party, diarization, code-switching

1. Executive Summary

본 프로젝트의 목표는 서로 다른 언어를 사용하는 두 화자가 동일한 대화 문맥에서 multi-turn 대화를 할 때, AI 통역기가 단순 번역 뿐 아니라 언제 듣고, 언제 번역을 시작하고, 언제 기다리고, 언제 중단하고, 어느 방향으로 전환할지를 실시간으로 판단하는 Conversational Simultaneous Speech-to-Text Translation 문제를 정의하고 해결하는 것이다.

기존 Simultaneous Speech Translation 은 대체로 단일 source stream 과 고정된 source→target 방향을 전제로 한다. 본 프로젝트는 이를 conversation-level interaction control 로 확장한다.

핵심 메시지: Existing simultaneous speech translation translates speech streams. We study simultaneous translation of conversations.

핵심 가설: In conversational simultaneous translation, translation policy and turn-taking policy are not independent.

첫 단계에서는 TTS 를 제외한 S2TT 로 범위를 제한한다. 이를 통해 음성 생성 품질, vocoder latency, prosody 등 부가 요인을 제거하고 turn-taking, semantic commitment, direction switching, interruption handling 을 명확히 평가한다.

2. 문제 정의

2.1 기본 시나리오

Speaker A (Language X)

↓

AI Interpreter

↓

Speaker B (Language Y)

두 화자는 하나의 대화 문맥을 공유하며 각자의 언어로 대화한다. 시스템은 양쪽 speech stream 을 실시간으로 관찰하고 적절한 시점에 상대 언어의 text translation 을 생성한다.

2.2 실시간 의사결정

WHO is speaking?

↓

Which translation direction?

↓

Is this a real turn or a backchannel?

↓

Is enough semantic information available?

↓

WRITE / WAIT?

↓

CONTINUE / STOP / SWITCH?

개념적 모델링: $P(Y_t, A_t, S_t | X_{\leq t}, H_t)$

- Y_t : translation output token
- A_t : interaction action
- S_t : speaker / turn state
- $X_{\leq t}$: 현재까지의 streaming speech input
- H_t : dialogue history

3. 기존 SimulST와의 차이

항목	기존 SimulST	CST-S2TT
Source speaker	주어짐	실시간 대화 상태에서 결정
Translation direction	고정	A→B / B→A 실시간 전환
Input unit	단일 speech stream / utterance	multi-turn conversation
Translation start	평가함	평가함
Semantic commit	일부 연구	핵심 문제
Backchannel	보통 고려 안 함	명시적 처리
Interruption	보통 고려 안 함	명시적 처리
Turn switching	외부 제어	모델/시스템이 판단
Output modality	text 또는 speech	본 연구는 text

4. 연구 범위

4.1 포함

- 2 명의 화자
- 서로 다른 언어
- 동일 conversation context
- 실제 multi-turn 대화
- streaming speech input
- simultaneous speech-to-text translation
- bidirectional translation
- semantic commitment
- turn switching
- backchannel
- interruption / early turn

4.2 첫 논문에서 제외


- TTS / vocoder / speech generation
- 음성 자연성, MOS, speaker similarity
- 3 명 이상 multi-party
- speaker diarization
- code-switching 을 핵심 task 로 다루는 것
- full end-to-end S2ST

S2ST 는 후속 extension 또는 demo 수준으로 확장한다.

5. Benchmark: CST-Bench

CST-Bench 는 “서로 다른 언어를 사용하는 두 사람이 대화할 때, 시스템이 translation quality 를 유지하면서 적절한 timing 과 direction 으로 번역하고 interaction event 에 대응할 수 있는가?”를 평가한다.

5.1 Natural Conversation Set



- translation quality
- semantic commit
- translation latency
- direction switching
- dialogue context utilization

5.2 Controlled Interaction Set

Original

A _____
B _____

Synthetic interruption

A _____
B _____
↑
interruption

실제 dialogue 의 linguistic content 와 turn dependency 는 유지하고 interaction timing 만 합성한다. 따라서 내용/화자/문맥은 동일하게 유지하면서 interaction condition 만 통제할 수 있다.

6. 원본 데이터 요구 조건

6.1 필수

- 동일 conversation/session
- 최소 2 명의 실제 화자
- 같은 session 안에서 서로 다른 언어 사용
- multi-turn
- shared conversational context
- 각 turn 의 speech audio
- speaker ID
- speaker language
- turn order
- transcript

6.2 권장

- reference translation
- turn start/end timestamp
- session-level audio
- 별도 speaker channel

6.3 배제 조건

- 한쪽 화자의 문장을 다른 사람이 별도로 낭독한 parallel speech
- text dialogue 를 speaker 별로 독립 녹음한 corpus
- 서로 다른 언어 corpus 를 단순히 합쳐 multilingual 이라고 부르는 데이터
- dialogue order 나 shared context 를 복원할 수 없는 utterance collection

7. 현재 데이터 확보 전략

후보	언어	역할/장점	상태
BAS TAXI	DE ↔ EN	실제 spontaneous telephone dialogue, turn-based, transcript/translation	우선 확보
Verbmobil II Multilingual	DE ↔ EN / DE ↔ JA	실제 multi-turn, human interpreter subset	우선 확보
BAAI CS-Dialogue	ZH / EN	104h 급 실제 2인 spontaneous dialogue, 공개 접근 쉬움	prototype
Bangor bilingual corpora	ES/EN, CY/EN, CY/ES	실제 자연대화 audio	보조 prototype
ETRI/SiTEC	KO ↔ EN	한국어에 가장 직접적	배포 경로 확인 필요

한국어 자체 수집 시 원본 interruption 까지 녹음할 필요는 없으며 자연스러운 turn-based multi-turn dialogue 만 확보하면 된다.

8. Synthetic Interaction Generation

8.1 Normal

A _____
B _____

8.2 Early Turn

A _____
B _____

8.3 Interruption

A _____
B _____

8.4 Backchannel

짧은 acknowledgment 를 삽입한다. 예: 한국어 “네/응/맞아요/음/그렇군요”, 영어 “yeah/right/uh-huh/okay/I see”.

A _____
B —
"yeah"

8.5 Explicit Barge-in

context-conditioned LLM + TTS 로 “잠시만요”, “Wait”, “Hold on”, “But what about...?” 등의 명시적 개입 발화를 생성할 수 있다.

9. Interruption 난이도 설계

Interruption onset 은 완전 random sampling 하지 않고 semantic chunk boundary 주변에서 선택한다.

이번 실험에서는 /
3B 모델을 사용하고 /
latency 를 줄이기 위해 /
streaming inference 를 적용합니다.

- Easy: turn end 직전
- Medium: semantic chunk boundary 부근
- Hard: 핵심 의미가 아직 완성되지 않은 시점

10. Semantic Commitment

S2TT 에서 semantic commitment 는 핵심 요소다. “내일 오전에... 아니 오후 세 시에 갈게요.” 같은 발화에서 너무 일찍 commit 하면 잘못된 번역을 되돌리기 어렵다.

Uncommitted text → 수정 가능

Committed text → 수정 불가능

메인 benchmark 는 revision-free committed translation 을 중심으로 설계한다.

- prefix translation stability
- future-context sensitivity
- semantic chunk boundary
- reference translation alignment

11. 모델 방향

기존 streaming speech sequence modeling 을 Conversational SimulST 로 확장한다. 실제 special token 수는 최소화하고 benchmark 는 특정 architecture 를 강제하지 않는다.

<NEXT_AUDIO>

<WAIT>

<A_T0_B>

translation tokens ...

<CONTINUE>

<BACKCHANNEL>

<CONTINUE>

<INTERRUPT>

<STOP>

<B_T0_A>

translation tokens ...

Benchmark 는 어떤 text 를, 언제, 어느 direction 으로 출력했는지와 interaction event 에서의 행동만 평가한다.

12. Baseline 설계

Baseline	구성	목적
B0	Offline ST	번역 품질 reference
B1	$2 \times \text{SimulST (A} \rightarrow \text{B, B} \rightarrow \text{A)}$	가장 단순한 bidirectional baseline
B2	VAD + $2 \times \text{SimulST}$	speech activity 기반 routing
B3	VAP + $2 \times \text{SimulST}$	turn-taking predictor 결합

B4	Oracle Turn Boundary + 2 × SimulST	interaction bottleneck upper bound
B5	Joint Conversational SimulST	제안 모델

13. 평가 Metric

13.1 Translation Quality

- COMET 계열
- BLEU
- chrF

13.2 Streaming / Latency

- Average Lagging
- LAAL
- First-token latency
- Semantic commit latency

13.3 Interaction Quality

- Turn Direction Accuracy: A→B / B→A / NONE
- False Stop / False Switch Rate
- Missed Interruption Rate
- Stop Latency
- Switch Latency
- Wrong-direction Translation Rate

Stop Latency = last old-direction token time - interruption onset

Switch Latency = first new-direction token time - new turn onset

14. 핵심 실험

Model	Translation	Normal Turn	Backchannel	Interruption	Switch Latency
2×SimulST	Good	Good	Poor	Poor	Poor
+ VAD	Good	Good	Poor	Fair	Fair
+ VAP	Good	Good	Fair	Good	Good
Joint	Good	Good	Good	Good	Good
Oracle	Upper bound	-	-	-	Upper bound

목표는 기존 시스템이 translation 은 잘하지만 conversation-level interaction 에서 실패한다는 것을 정량적으로 보여주는 것이다.

15. Kill Criterion

Joint architecture 개발 전에 “VAP + 2× strong SimulST pipeline 만으로도 Controlled Interaction Set 에서 거의 모든 interaction metric 이 해결되는가?”를 먼저 검증한다.

15.1 연구 지속에 유리한 결과

- backchannel 에서 false switch 지속
- interruption 대응 지연

- semantic correction 에서 early commit 오류
- rapid turn switching 에서 direction 오류 증가
- oracle turn 정보를 주면 큰 폭 개선

15.2 방향 재검토가 필요한 결과

- strong pipeline 이 Joint model 없이도 거의 모든 condition 을 해결
- interaction-aware modeling 이 translation/latency 에 실질적 이득을 주지 못함

16. 개발 및 연구 단계

단계	핵심 작업	Deliverable
Phase 0 - Feasibility / Data Access	접근 가능한 cross-lingual corpus 확보, parser 개발, TAXI/Verbmobil 접근 병행	원본 dialogue → 공통 schema parser
Phase 1 - CST Data Pipeline	turn reconstruction, speaker/language mapping, translation normalization, synthetic timeline generator	Natural / Early-turn / Interruption / Backchannel sample generator
Phase 2 - CST-Bench v0	Natural Set, Controlled Interaction Set, metrics, revision-free commit protocol	모델 독립 evaluation toolkit
Phase 3 - Strong Baselines	2× SimulST, VAD, VAP, Oracle	pipeline limitation 분석
Phase 4 - Joint Model	turn/commit/translation joint modeling	제안 모델 및 ablation
Phase 5 - Korean Extension	ETRI 확보 또는 KO↔EN 소규모 수집	한국어 benchmark 확장
Phase 6 - S2ST Extension	Streaming TTS 연결	후속 full S2ST demo/research

17. 당장 준비해야 할 항목

17.1 데이터

- 즉시 접근 가능한 cross-lingual dialogue 확보
- TAXI / Verbmobil 접근 경로 지속 확인
- ETRI KO↔EN 배포 가능성 확인
- 데이터 라이선스와 변형/재배포 조건 정리

17.2 데이터 처리

- unified conversation schema 설계
- dialogue parser 구현
- turn-level audio normalization
- semantic chunk segmentation
- controlled timeline generator 구현

17.3 Baseline

- strong SimulST 모델 선정
- bidirectional 2× SimulST routing 구현
- VAD baseline
- VAP baseline
- oracle routing baseline

17.4 평가

- translation metrics
- streaming latency metrics
- direction accuracy
- false stop/switch
- missed interruption
- stop/switch latency

17.5 연구 검증

- pipeline failure case 수집
- oracle gap 측정
- joint modeling 필요성 판단

18. 예상 논문 Contribution

1. Task: continuous cross-lingual conversation 을 위한 Conversational Simultaneous S2TT 정의
2. Benchmark: real dialogue content + controlled interaction timing 기반 CST-Bench
3. Metrics: translation 뿐 아니라 turn direction, interruption, backchannel, switching latency 를 평가하는 protocol
4. Model: translation policy 와 turn-taking/commit policy 를 joint 하게 모델링하는 streaming architecture

19. 프로젝트 성공 기준

- 기존 2×SimulST 가 natural dialogue 에서는 잘 동작하지만 controlled interaction 에서 명확히 성능 저하
- VAP 등의 interaction module 이 일부 개선하되 residual gap 존재
- Joint model 이 translation quality 를 크게 희생하지 않으면서 interaction metrics 를 유의하게 개선
- 결과가 여러 language pair 에서 반복

가장 강한 결과 예시: Oracle turn information closes much of the gap, while the proposed joint model recovers a substantial portion of that oracle gain without external turn labels.

20. 최종 프로젝트 정의

실제 **cross-lingual multi-turn conversation** 을 기반으로 **controlled interaction benchmark** 를 구축하고, **conversational turn-taking** 과 **semantic commitment** 를 **simultaneous speech-to-text translation** 과 **joint** 하게 모델링함으로써 기존 **cascaded SimulST** 시스템의 한계를 분석하고 극복하는 연구.

현재 최우선 작업

모델 개발보다 CST-Bench v0 와 strong pipeline baseline 을 먼저 완성한다. 가장 먼저 확인해야 할 질문은 “Conversation-level interaction 을 명시적으로 다루지 않는 기존 SimulST pipeline 은 실제로 어디에서, 얼마나 실패하는가?”이다.